Laboratorio 9 — Task 1

Arquitecturas de Segmentación para Cabinas Fotográficas AR — *Akihabara Fest*

Andy Fuentes *22944*
Diederich Solis *22952*
Christian Echeverría *221441*

Repositorio: https://github.com/Andyfer004/Lab9vC
Video de funcionamiento: https://youtu.be/cOfggxx4n24

A continuación se presenta la investigación solicitada por la mesa directiva respecto a las arquitecturas U-Net y Mask R-CNN, evaluando cuál es apropiada para cada una de las dos tareas de las Cabinas Fotográficas AR.

Diferencia fundamental a nivel de píxel

La distinción entre segmentación semántica y segmentación de instancia se resuelve en la **etiqueta que recibe cada píxel** de la imagen de salida.

Segmentación Semántica: a cada píxel (x, y) se le asigna *únicamente* un identificador de clase $c \in \{0, 1, \ldots, K-1\}$, donde K es el número de categorías del modelo. Todos los píxeles que pertenecen a la misma categoría reciben *exactamente la misma etiqueta*, sin importar si provienen de objetos físicamente distintos. Si tres personas aparecen en el frame, los píxeles de las tres personas son indistinguibles en la máscara: todos son "persona".

Segmentación de Instancia: a cada píxel se le asigna una tupla (c, i) compuesta por un identificador de clase c y un identificador de instancia $i \in \{1, 2, 3, \ldots\}$. Dos personas en la misma foto tendrán la misma clase $c =$ `persona`, pero distintos i (persona_1, persona_2, persona_3). La salida ya no es un único canal de clases, sino un conjunto de máscaras binarias independientes, una por cada objeto detectado.

En una línea: la semántica responde "*¿qué es este píxel?*"; la de instancia responde "*¿qué es y a cuál objeto individual pertenece?*".

El caso U-Net — Tarea 1 (fondo vs. humanos)

Por qué U-Net es ideal para la Tarea 1. La Tarea 1 es un problema estricto de *binary semantic segmentation*: clasificar cada píxel como `humano` o `fondo`. U-Net (Ronneberger et al., 2015) fue diseñada exactamente para este tipo de salida densa píxel a píxel. Su arquitectura encoder–decoder en forma de "U" reduce la resolución espacial para capturar contexto semántico en el *bottleneck*, y luego la reconstruye mediante *upsampling* progresivo. Las **skip connections** entre niveles simétricos reinyectan información de alta resolución, lo que permite recuperar bordes finos — crítico para un chroma key limpio que no deje halos alrededor del cabello o los accesorios del cosplayer. Además, U-Net es computacionalmente ligera (pocos millones de parámetros en su versión base), lo que la hace adecuada para inferencia en tiempo real dentro de la cabina. Como la Tarea 1 no necesita distinguir *cuántos* humanos hay ni *cuál es cuál* — basta con saber qué píxeles son "foreground" para reemplazar el resto por Konoha o Neo-Tokyo — la segmentación semántica es suficiente y eficiente.

Por qué U-Net fracasa en la Tarea 2 (dos espadas idénticas cruzadas). U-Net produce un único mapa de probabilidad por clase. Si entrenamos la red con la clase `espada`, la salida es una matriz $H \times W$ donde cada píxel vale 1 si es espada y 0 si no lo es. Cuando dos espadas idénticas se cruzan en la foto, **la red fusiona ambas en una única región conectada de píxeles marcados como `espada`**: no existe en la arquitectura ningún mecanismo que codifique identidad de instancia. El punto de intersección de las hojas es ambiguo incluso para un humano a nivel de píxel —¿pertenece a la espada A o a la espada B?—, y U-Net simplemente no se hace esa pregunta. En consecuencia, al intentar superponer el efecto de brillo, el engine gráfico recibe una sola máscara fusionada y aplica un único color a ambas espadas, o peor, a una silueta compuesta que atraviesa ambas hojas. **No es un problema de precisión del modelo, es una limitación de su formulación matemática de salida.**

El caso Mask R-CNN — resolviendo la Tarea 2

Mask R-CNN (He et al., 2017) hereda la filosofía de **dos etapas** de Faster R-CNN y añade una rama de segmentación. El flujo es:

1. **Etapa 1 — Region Proposal Network (RPN):** un backbone convolucional (típicamente ResNet + FPN) genera *feature maps*, y sobre estos la RPN propone miles de *bounding boxes* candidatas (*Regions of Interest* o RoIs) que probablemente contienen un objeto, cada una con un *objectness score*.

2. **Etapa 2 — cabezas paralelas por RoI:** cada RoI se alinea a una cuadrícula fija mediante `RoIAlign` (interpolación bilineal sin cuantización, corrigiendo el problema de `RoIPool` de Faster R-CNN), y se le aplican tres cabezas independientes: (a) clasificación de la clase, (b) regresión del *bounding box*, y (c) una **máscara binaria** $m \times m$ predicha por una pequeña FCN.

Por qué sí puede iluminar una espada de rojo y otra de azul. La clave está en que **la máscara se predice *dentro* de cada RoI de manera independiente**, no sobre la imagen global. Aunque las dos espadas estén tocándose en el espacio de la imagen, la RPN genera *dos RoIs separadas* (cajas A y B), una para cada espada, porque cada una tiene su propio centro, escala y *objectness score*. Luego, la cabeza de máscara procesa la RoI A y la RoI B por separado, produciendo dos máscaras binarias distintas: M_A y M_B. Ambas pueden incluso cubrir píxeles comunes en la zona de cruce — no es un problema, porque están ligadas a identidades de instancia diferentes ($i = A$, $i = B$). El motor de AR recibe entonces **dos estructuras separadas** y puede pintar una en rojo y otra en azul con total libertad.

> **Recomendación técnica.** Usar **U-Net** para la *Tarea 1* (chroma key del fondo: rápido, preciso en bordes, bajo costo en edge) y **Mask R-CNN** para la *Tarea 2* (efectos por instancia sobre armas: único modelo capaz de separar objetos idénticos superpuestos en una misma foto). Un pipeline de dos modelos especializados supera en calidad y costo a un único modelo generalista.

Task 2 — Oclusión, IoU y NMS en multitudes densas

En una escena con 15 personas muy juntas, el detector puede generar múltiples cajas candidatas para regiones similares del cuerpo de varios individuos. El problema aparece cuando esas cajas tienen un alto solapamiento entre sí. El algoritmo *Non-Maximum Suppression* (NMS) conserva la caja con mayor confianza y elimina las demás si su solapamiento excede un umbral definido.

1. Por qué NMS hace que desaparezcan clones superpuestos

El criterio principal de NMS se basa en la métrica *Intersection over Union* (IoU), definida como:

$$IoU(A, B) = \frac{\text{área}(A \cap B)}{\text{área}(A \cup B)}$$

donde A y B son dos *bounding boxes*. Si dos personas están muy pegadas, abrazadas o parcialmente ocluidas, las cajas predichas para cada una pueden cubrir regiones muy parecidas. En ese caso, el valor de IoU entre ambas cajas aumenta. Si dicho valor supera el umbral de NMS, el algoritmo asume que ambas cajas corresponden al mismo objeto y elimina una de ellas.

Matemáticamente, si una caja B_j cumple:

$$IoU(B_i, B_j) > \tau_{NMS}$$

siendo B_i la caja de mayor confianza y τ_{NMS} el umbral configurado, entonces B_j es descartada. En escenas densas esto genera **falsos negativos**, porque cajas válidas de personas distintas son suprimidas por tener demasiado solapamiento.

2. Efecto de cambiar el umbral de IoU en NMS

Si se ajusta el umbral a $\tau_{NMS} = 0{,}15$, el criterio se vuelve extremadamente agresivo. Basta con que dos cajas se solapen un poco para que una sea eliminada. En un escenario de alta densidad, esto empeora el problema: desaparecerán más personas porque muchas detecciones legítimas tendrán IoU mayor a 0.15.

Si se ajusta el umbral a $\tau_{NMS} = 0{,}95$, el criterio se vuelve extremadamente permisivo. Casi ninguna caja será eliminada, por lo que muchas detecciones muy similares permanecerán en pantalla. Esto reduce la pérdida de personas verdaderas, pero introduce muchas cajas duplicadas sobre el mismo individuo.

Para este caso de alta oclusión, un valor **intermedio-alto** es más adecuado, por ejemplo entre 0.6 y 0.8. Ese rango permite conservar más detecciones de personas realmente distintas sin dejar pasar demasiados duplicados. Entre las dos opciones dadas, **0.95 preserva mejor a los clones** que 0.15, aunque puede producir redundancia visual.

Conclusión de inferencia. En escenas con muchas personas superpuestas, un umbral muy bajo de NMS incrementa los falsos negativos; un umbral muy alto reduce la supresión excesiva, aunque puede dejar cajas repetidas. Para este problema, conviene priorizar conservar detecciones antes que eliminarlas agresivamente.

3. Cómo YOLOv10 ayuda con Dual Label Assignment

YOLOv10 fue diseñado para reducir la dependencia del postprocesamiento tradicional y mejorar la asignación de ejemplos durante el entrenamiento. Su estrategia de *Dual Label Assignment* permite que el modelo aprenda con dos criterios complementarios: uno más flexible para enriquecer la supervisión durante el entrenamiento y otro más estricto para producir predicciones más limpias durante la inferencia.

Esto mejora el comportamiento en oclusión porque el modelo aprende a representar mejor objetos cercanos, parcialmente visibles o muy similares entre sí. En lugar de depender fuertemente de NMS para decidir cuál caja sobrevive, la red genera salidas más consistentes desde su propia formulación. En consecuencia, cuando aparecen varios clones superpuestos, YOLOv10 tiene mayor capacidad para mantener detecciones separadas sin colapsarlas tan fácilmente en una sola.

Task 3 — Prototipo funcional evidencia video

Video de funcionamiento: https://youtu.be/cOfggxx4n24